

AI原生应用架构探索与实践

加速 AI 应用发生～

彦林（李艳林）

阿里云- API网关和微服务负责人 / 开源Higress/Nacos创始人

2025/04

CONTENT 目录


01 AI 原生应用架构探索

02 AI 云原生应用架构实践

03 AI 原生应用架构客户案例

04 AI 原生应用架构规划

应用架构演进





AI 原生应用架构

AI 原生应用架构：基于模型，Agent 驱动，以数据为中心，整合工具链




AI 应用框架 趋势

基模 API / 框架 / 低代码？ Python (langchain&LlamaIndex) / Java？



数据来源：《2023 CSDN 中国开发者报告》

AI 原生应用架构图




AI 网关实践 (Higress: 一键集成多种数据源)



AI Tools 实践 (Nacos: MCP Register)

应用0代码改动，Nacos提供服务Endpoint以及服务Tools Prompt，基于Higress转换MCP协议



AI 配置实践（Nacos：动态更新提示词数据）





AI 观测实践（Otel：全链路数据质量追踪）

为 GenAI 应用可观测而生

阿里云 ARMS

可观测链路追踪 OpenTelemetry 版

LlamaIndex LangChain

DIFY Spring-AI-Alibaba

OpenAI

通义千问

OpenTelemetry GenAI 语义约定

持续剖析

稳定性

LLM SDK


阿里云 OTel Python 发行版

阿里云 OTel Java 发行版

阿里云 Go 探针


- 循序最新 OpenTelemetry 社区 GenAI 语义约定
- 支持常见的 AI 框架和 AI 模型，包括 Spring-AI-Alibaba / LlamaIndex / Langchain / 通义千问2 / OpenAI / PromptFlow
- 相比社区规范提供更加精细化的埋点和属性
- 支持在不同的调用链中传播会话信息

大模型应用专属分析视图




- RAG 过程
- 提示词输入、输出
- Token 消耗


AI 事件驱动实践 (RocketMQ: 提升 RAG数据实时性)




DeepSeek 数据安全+联网解决方案



DIFY 高可用解决方案




标杆客户 – 阿里云内部实践



Higress作为流量网关，白屏操作

- ✓ 支持长连接SSE/WebSocket，热更新对长连接流量无损
- ✓ 支持流式传输，满足AI大带宽/高延时特性诉求
- ✓ 支持多种安全认证与限流防护


AI 应用



Higress作为流量网关，白屏操作

- ✓ 支持长连接SSE/WebSocket，热更新对长连接流量无损
- ✓ 支持流式传输，满足AI大带宽/高延时特性诉求
- ✓ 高可用，99.999% SLA

AI 模型服务平台




使用 Ingress 配置路由，通过Ingress集成PAI的管控

- ✓ 支持1W+ 超大路由/域名规模场景，多租共享集群模式，切换到Higress后路由配置生效RT从原10分钟降到30秒内
- ✓ 构建完善可观测体系

AI 模型

标杆客户 - 零一万物

在入口建立安全 & 高可用防线 & Serverless



标杆客户 – 震坤行


震坤行工业超市是一家数字化的工业用品服务平台，为客户提供一站式的工业用品采购与管理服务。



核心优势


- 零代码构建
- 生产级可用
- 丰富AI插件
- 缓存提速降本
- 安全零信任
- 一键诊断分析

AI 视频处理 实践




AI 应用架构规划：构建以数据为中心智能体平台

基于模型，Agent驱动，以数据为中心，整合工具链；充分挖掘私域数据，提升数据质量。



AI 网关规划： MCP 市场生态



Spring AI Alibaba 规划（多Agent，多模态，多场景）

Development Tools

Tools and services to facilitate project initialization and development.

Spring AI Alibaba Studio

Project Initializer

Low-code
workflow

Project
Template

Spring AI Alibaba Studio

RAG
Evaluation

Visualized
Debug

Tracing

Agentic Framework

Framework for creating agent and multi-agent workflows

Spring AI Alibaba Graph

workflow

Agent

ReAct Agent

Multi Agent

.....

Low-level AI Framework

Spring AI based abstractions for developing Chatbot and RAG applications.

Spring AI Alibaba Core

ChatClient

ChatModel

DocumentReader

Embedding

Nacos

LLM Model

Function

TextSplitter

Retriever

Higress

Memory

Prompt

VectorStore

Retriever

Observability

Spring AI Alibaba 规划 (建立Java开发者与阿里云AI产品链接)

Spring AI Alibaba

模型&应用服务

- DashScope 模型
- 百炼：智能体、RAG与低代码开源平台

向量存储

- DashVector
- OpenSearch
- ADB
- Tair

微服务引擎

- Nacos MCP发现
- Nacos配置管理
- Spring Cloud Alibaba MCP 发布

AI 网关

- 模型代理
- MCP 代理

插件与工具

- 云市场插件
- 信息检索服务
- 云上MCP服务

可观测


- ARMS

Serverless

- MCP FC 运行时
- SAA 运行时

AI Agent with MCP

AI原生应用架构下 Prompt + MCP Tools 动态规划处理各类不同的场景




欢迎加入我们~

钉钉二维码



微信二维码



 阿里云 | 计算,为了无法计算的价值